

Modelagem Preditiva Avançada

Atividade Prática Supervisionada

Primeiro Semestre de 2026

Professor: Paulo C. Marques F.

1 FORMAÇÃO DOS GRUPOS

Esta atividade prática supervisionada deverá ser feita em grupos de até 4 integrantes, sem exceções para grupos maiores. Se desejado, a atividade poderá ser feita individualmente, mas isso deveria ser evitado: você aprenderá muito mais interagindo e trabalhando pelo menos em dupla. Um dos integrantes do grupo deverá enviar um e-mail para o professor no endereço PauloCMF1@insper.edu.br até o dia 3 de Maio às 23h59 informando os nomes de todos os integrantes.

Importante: alunas e alunos de Direito devem formar o grupo com integrantes de outros cursos. Veremos abaixo que alguns itens da atividade envolvem ideias básicas do Cálculo (derivada parcial, regra da cadeia etc), que já foram articuladas nas aulas. De maneira alguma será cobrado dos estudantes de Direito um domínio destas técnicas. No entanto, espera-se que haja um bom entendimento intuitivo do funcionamento geral de todos os conceitos envolvidos.

Os grupos apresentarão o conteúdo da atividade na aula de 20 de maio. Atenção: não divida a execução e o entendimento completo do conteúdo da atividade. Todos os integrantes do grupo deverão ser capazes de discutir na lousa o conteúdo completo da atividade, sob risco de penalização da nota de todo o grupo. O relatório pode ser redigido com qualquer ferramenta, mas sempre gere PDF no final do processo. Não é necessário criar *slides* adicionais para a apresentação, que deverá ser feita a partir do próprio relatório apresentado. Os códigos R ou Python desenvolvidos pelo grupo, bem como as saídas geradas por estes códigos, devem aparecer no próprio relatório. Não envie arquivos de código em separado. Organize bem a formatação do relatório e capriche. Organização e capricho farão parte da nota da atividade. Apenas um dos integrantes do grupo deverá fazer a entrega do relatório via link do Blackboard no dia 20 de maio até 23h59.

O uso de IAs para a realização de qualquer tarefa já é algo totalmente disseminado. No entanto, todo o conteúdo e o texto desta atividade deverá ser de autoria dos integrantes do grupo. Faça sua atividade de maneira responsável. Nunca apresente resultados que você não entendeu e não saberá explicar na lousa no dia da apresentação da atividade. Nunca apresente um código R ou Python cujo funcionamento você não entenda perfeitamente.

Esta atividade trabalhará conceitos de duas arquiteturas de redes neurais que não foram detalhadas em aula: as redes neurais recorrentes e as redes neurais convolucionais.

2 REDES NEURAS RECORRENTES

Fizemos em aula um estudo detalhado da implementação do processo de *backpropagation* para três arquiteturas de redes neurais: as redes *feedforward* para regressão e classificação (também denominadas *Multi Layer Perceptron*, ou MLP) e o *autoencoder*. Temos informações detalhadas sobre o cálculo dos respectivos gradientes nos slides de aula e há códigos R implementando todos os exemplos de *backpropagation* no Blackboard.

Aqui consideraremos uma outra arquitetura adequada a dados do tipo série temporal: a rede neural recorrente. Imagine que observemos uma sucessão de valores $y_1, y_2, \dots, y_n$. Nosso objetivo será prever o valor de y_t a partir dos dois valores anteriores y_{t-1} e y_{t-2} . Para tanto definimos, para $t = 3, \dots, n$, a arquitetura recorrente

$$h_{t,1} = \tanh(a y_{t-2} + c)$$

$$h_{t,2} = \tanh(a y_{t-1} + b h_{t,1} + c)$$

$$\hat{y}_t = u h_{t,2} + v$$

na qual temos os cinco parâmetros (u, v, a, b, c) e as variáveis auxiliares não observáveis (“latentes”) $h_{t,1}$ e $h_{t,2}$ são denominadas estados ocultos (*hidden states*) da rede neural recorrente.

A função de perda para este problema será $L = L(u, v, a, b, c) = \frac{1}{2} \sum_{t=3}^n (y_t - \hat{y}_t)^2$. Definindo as parcelas $L_t = \frac{1}{2} (y_t - \hat{y}_t)^2$, podemos reescrever esta perda total como $L = \sum_{t=3}^n L_t$.


Apresente os cálculos das cinco componentes do vetor gradiente para esta rede neural, conforme fizemos em aula para as outras arquiteturas. Os cálculos devem ser feitos à mão, as contas devem ser fotografadas com o celular e a imagem deve ser colada no relatório. Capricho e organização farão parte da nota do relatório.

Como dica e exemplo do que deve ser feito, este é o resultado obtido pelo professor para uma das cinco componentes do gradiente solicitadas:

$$\frac{\partial L_t}{\partial a} = \frac{\partial L_t}{\partial \hat{y}_t} \frac{\partial \hat{y}_t}{\partial h_{t,2}} \frac{\partial h_{t,2}}{\partial a} = (\hat{y}_t - y_t) u (1 - h_{t,2}^2) (y_{t-1} + b (1 - h_{t,1}^2) y_{t-2}).$$

Dica: a derivada total da tangente hiperbólica é dada por $\frac{d \tanh(x)}{dx} = 1 - \tanh^2(x)$. Ou seja, se $h = \tanh(s)$, então $\frac{dh}{ds} = 1 - h^2$. Utilize este fato em seus cálculos, que envolverão derivadas parciais, conforme fizemos em aula.

Escreva código R ou Python implementando o *backpropagation* para esta rede neural recorrente. Este processo é conhecido na literatura como *backpropagation through time*. Utilize os códigos R das outras arquiteturas disponibilizados no Blackboard como referência. Neste item é proibido utilizar quaisquer bibliotecas de redes neurais (PyTorch, Tensorflow, JAX, Keras etc). O dado será a série temporal clássica **AirPassengers** disponível no R e no Python. Esta série temporal mostra a evolução do número mensal de passageiros em voos comerciais internacionais. Defina y_t como sendo o logaritmo natural do número mensal de passageiros. Pesquise na literatura por que é uma boa ideia fazer esta transformação logarítmica e apresente um argumento no relatório. Ao treinar a rede neural recorrente, utilize 10^5 épocas. Note que nesta arquitetura recorrente não fazemos aprendizagem *on-*



line (uma observação por vez), nem utilizamos mini-lotes. Para esta arquitetura recorrente, em cada época do treinamento, calculamos o gradiente para a perda total: $\nabla L = \sum_{t=3}^n \nabla L_t$. Utilize o valor $\delta = 0.05/n$ para a taxa de aprendizagem, em que n é o comprimento da série temporal **AirPassengers**. Dica: inicialize os valores dos parâmetros (u, v, a, b, c) sorteando de uma distribuição normal com média igual a zero e desvio-padrão igual a 0.1. Depois de ter treinado a rede neural, você fará previsões na própria série **AirPassengers**. Ou seja, serão previsões *in-sample* (dentro da amostra), apenas para testarmos o ajuste da rede neural recorrente obtida. Cuidado: lembre-se de calcular a exponencial dos valores previstos por sua rede neural recorrente, uma vez que treinamos a rede com o logaritmo do número mensal de passageiros. Faça um gráfico sobrepondo os valores originais da série **AirPassengers**, em azul, com os números de passageiros previstos mensalmente pela sua rede neural recorrente, em vermelho. Como dica e exemplo, veja acima a figura gerada pelo código do professor. Observação: o código do professor roda em aproximadamente 10 segundos. Não complique seu código desnecessariamente. Trata-se de um código simples.

3 REDES NEURAS CONVOLUCIONAIS

Nesta parte da atividade trataremos das Redes Neurais Convolucionais (*Convolutional Neural Networks*, ou simplesmente ConvNets). Pesquise bastante nas fontes que forem necessárias. Há informações básicas em nosso livro-texto, disponibilizado no Blackboard. Aprofunde as informações com buscas na Internet e outras fontes. Construa exemplos para explicar os conceitos envolvidos nas ConvNets. Os itens abaixo devem ser discutidos obrigatoriamente. Os artigos mencionados estão disponíveis na pasta APS do Blackboard. Com exceção das figuras geradas pelo códigos do item (6), todas as figuras dos exemplos devem ser feitas à mão, fotografadas com o celular e coladas no relatório. Desenvolva suas próprias figuras. Seja capaz de desenhar as figuras na lousa no dia da apresentação da atividade, se assim solicitado. Portanto, não utilize figuras prontas da Internet que você não entende, ou que tenham sido geradas por IAs. A qualidade, criatividade e organização das figuras fará

parte da nota da atividade.

1. Qual a história das ConvNets? Descreva o trabalho pioneiro de Fukushima (1980) no Neocognitron. Levando em conta o que estudamos nas aulas de redes neurais, qual elemento faltava a Fukushima no treinamento do Neocognitron? Descreva o trabalho de Yann LeCun et al. (1998) e a arquitetura LeNet-5. Quais as inovações deste trabalho? Finalmente: será que houve alguma injustiça histórica em relação ao valor da contribuição do trabalho de Fukushima? Investigue.
2. No contexto das ConvNets, o que é uma convolução? Construa um exemplo com figuras. Explique detalhadamente.
3. Como funciona a camada de *Max Pooling* e qual o seu papel na arquitetura de uma ConvNet? Explique detalhadamente exemplificando com figuras.
4. No contexto de classificação de imagens com ConvNets, como funciona e qual o propósito da técnica de *Data Augmentation*? Explique detalhadamente.
5. No que consiste a inovação introduzida pelas *Residual Neural Networks* de He et al.? Qual a relevância e o impacto destas ideias na implementação das ConvNets?
6. Construa uma ConvNet para classificação dos dígitos da base de dados MNIST. Utilize os códigos PyTorch de aula como ponto de partida. Lembre-se de que você pode executar os códigos PyTorch diretamente no Google Colab gratuitamente. Não é necessário instalar softwares em sua máquina para executar este item da atividade. Obtenha a acurácia do modelo e compare com os resultados obtidos em aula com a rede neural básica *feedforward* (MLP). Fazendo um gráfico em separado para cada modelo, crie uma família de curvas ROC utilizando a técnica OVA (*One-Versus-All*). Pesquise por conta própria na literatura como executar a OVA em problemas de classificação multi-classe. Descreva a OVA em detalhe. Como interpretar os resultados que você obteve? Cuidado: não é necessário retreinar o modelo múltiplas vezes.

Quando finalizar a atividade, estude muito cada conceito utilizado e cada código apresentado no relatório.